

**UNIVERSIDADE ESTÁCIO DE SÁ
CAMPUS: NITERÓI**

**ANÁLISE DE DADOS EM BIG DATA SOBRE CRIMINALIDADE BASEADA EM
ESCOLARIDADE NAS CIDADES DO RIO DE JANEIRO, NITERÓI E SÃO
GONÇALO**

**Alunos: Thadeu Moreira e Eduardo Monteiro
Professor orientador: Simone Ingrid**

**2026
Niterói/RJ**

Sumário

1.	DIAGNÓSTICO E TEORIZAÇÃO.....	3
1.1.	Problemática e/ou problemas identificados	3
1.2.	Justificativa	3
1.3.	Objetivos.....	4
2.	PLANEJAMENTO E DESENVOLVIMENTO DO PROJETO	4
2.1.	Plano de trabalho	4
2.2.	Grupo de trabalho	5
2.3.	Detalhamento técnico do projeto	6
3.	ENCERRAMENTO DO PROJETO	7
3.1.	Relatório Coletivo:	7
3.1.1.	CONSIDERAÇÕES FINAIS	8

1. DIAGNÓSTICO E TEORIZAÇÃO

Este projeto de extensão está voltado para a análise de dados públicos de criminalidade nos municípios de Rio de Janeiro, Niterói e São Gonçalo, utilizando tecnologias de Big Data com linguagem Python.

1.1. Problemática e/ou problemas identificados

O estado do Rio de Janeiro apresenta historicamente índices de criminalidade entre os mais elevados do país, com concentração significativa na Região Metropolitana. Os municípios de Rio de Janeiro, Niterói e São Gonçalo, apesar de geograficamente próximos, apresentam realidades socioeconômicas bastante distintas, o que se reflete diretamente em seus padrões de violência.

A problemática central identificada por este projeto consiste na ausência de análises sistematizadas e acessíveis que integrem dados criminais mensais com indicadores educacionais nos três municípios mencionados, dificultando a compreensão da relação entre escolaridade e criminalidade no período de 2020 a 2024. Essa lacuna foi percebida a partir de discussões em sala de aula, leitura de notícias locais e escuta informal de moradores dos municípios em questão, que demonstraram interesse em compreender as causas estruturais da violência em suas cidades.

A situação-problema priorizada é, portanto: como os dados abertos disponíveis podem ser utilizados para revelar padrões de criminalidade e sua possível correlação com indicadores de educação nos municípios de Rio de Janeiro, Niterói e São Gonçalo entre os anos de 2020 e 2024?

1.2. Justificativa

A pertinência acadêmica deste projeto fundamenta-se na crescente demanda por profissionais de Tecnologia da Informação capazes de trabalhar com grandes volumes de dados (Big Data) para a produção de conhecimento socialmente relevante. A Análise de Dados Públicos constitui um campo de aplicação direta dos conteúdos trabalhados no curso de análise de big data, especialmente nas disciplinas de programação em Python, estatística aplicada, visualização de dados e banco de dados.

Do ponto de vista social, a produção de análises baseadas em evidências sobre criminalidade contribui para subsidiar políticas públicas de segurança, além de promover transparência e acesso da sociedade às informações produzidas pelo poder público. A escolha dos municípios

da Região Metropolitana do Rio de Janeiro justifica-se pela sua relevância demográfica e pela disponibilidade de dados históricos sistematizados.

As motivações do grupo de trabalho estão ancoradas no interesse coletivo em aplicar as competências técnicas adquiridas ao longo do curso em um problema real, concreto e de relevância comunitária, demonstrando que a formação em tecnologia pode ser colocada a serviço da sociedade.

1.3. Objetivos

Objetivo Geral:

Analisar comparativamente os padrões de criminalidade nos municípios de Rio de Janeiro, Niterói e São Gonçalo entre 2020 e 2024, correlacionando os dados com indicadores educacionais por meio de técnicas de Big Data em Python.

Objetivo Específico:

- a) Coletar, processar e analisar dados públicos de criminalidade do ISP-RJ e indicadores de educação do IBGE para os municípios de Rio de Janeiro, Niterói e São Gonçalo, no período de 2020 a 2024, utilizando a linguagem Python e bibliotecas de Big Data;
- b) Identificar padrões e tendências nos dados de criminalidade e correlacioná-los com indicadores de escolaridade, produzindo visualizações claras e acessíveis para o público não especializado;
- c) Disponibilizar os resultados da análise de forma compreensível para a comunidade, contribuindo para a compreensão das relações entre educação, desigualdade e segurança pública na Região Metropolitana do Rio de Janeiro.

2. PLANEJAMENTO E DESENVOLVIMENTO DO PROJETO

2.1. Plano de trabalho

O plano de trabalho foi estruturado de forma a contemplar todas as etapas previstas no Plano de Ensino da disciplina, distribuídas ao longo do semestre letivo. A organização das atividades considerou a sequência lógica de desenvolvimento de um projeto de análise de dados: levantamento do problema, coleta de dados, tratamento, análise e apresentação dos resultados.

Segue abaixo a estrutura do cronograma:

Etapa 1. Coleta automatizada dos dados do ISP-RJ via URL pública (Base Municipal Mensal), com tratamento de encoding latin-1

Etapa 2. Verificação da estrutura da base: número de linhas e colunas, tipos de variáveis (dtypes), contagem de valores nulos por coluna e registros duplicados

Etapa 3. Identificação dinâmica das colunas de controle: município (fmun), ano (ano) e mês (mes) — via busca parcial de string para garantir robustez a variações no nome das colunas

Etapa 4. Filtragem dos municípios Rio de Janeiro, Niterói e São Gonçalo, seleção das 19 variáveis criminais analisadas (hom_doloso, lesao_corp_morte, latrocinio, cvli, hom_por_interv_policial, lesao_corp_dolosa, estupro, roubo_transeunte, roubo_celular, roubo_em_coletivo, roubo_rua, roubo_veiculo, roubo_carga, furto_veiculos, furto_transeunte, estelionato, apreensao_drogas, posse_drogas, trafico_drogas) e recorte temporal 2020-2024

Etapa 5. Limpeza e padronização: renomeação das colunas de controle para municipio/ano/mes, conversão das variáveis criminais para tipo numérico (pd.to_numeric com errors=coerce), criação da coluna de data (formato YYYY-MM-01) e remoção de linhas com nulos nas variáveis criminais

Etapa 6. Carregamento dos dados educacionais do IBGE via repositório GitHub, contendo as colunas: municipio, media_anos_estudo, perc_superior e taxa_analfabetismo

Etapa 7. Cálculo do índice composto de escolaridade com normalização min-max: media_anos_estudo (peso 0,4) + perc_superior (peso 0,4) + inverso da taxa_analfabetismo (peso 0,2), gerando a coluna indice_escolaridade

Etapa 8. Agregação dos crimes por município (groupby + sum) e integração (merge inner) com os dados educacionais pela coluna municipio, formando a base unificada df_edu_crime_mun

Etapa 9. Análise exploratória, visualizações comparativas e interpretação da correlação entre indice_escolaridade e as variáveis criminais

2.2. Grupo de trabalho

O grupo de trabalho foi composto pelos seguintes membros, com as respectivas responsabilidades:

Thadeu Moreira e Eduardo Monteiro — Responsáveis pela coleta e carregamento da base de dados do ISP-RJ via URL pública utilizando linguagem Python; filtragem e limpeza da base de dados.

Thadeu Moreira — Responsável pela análise exploratória dos dados, construção do índice de escolaridade e merge das bases ISP-RJ e IBGE.

Eduardo Monteiro — Responsável pela geração de gráficos e visualizações

2.3. Detalhamento técnico do projeto

A) Tema Escolhido:

A escolha desse tema se justifica pela necessidade de compreender como a desigualdade educacional impacta diretamente a segurança pública no Grande Rio. Analisar o cruzamento de dados entre os índices de criminalidade e os níveis de escolaridade no Rio de Janeiro, Niterói e São Gonçalo permite identificar os gargalos sociais específicos de cada região. Com o uso de ferramentas de Big Data, torna-se possível extrair padrões complexos que antes ficavam ocultos em grandes volumes de dados. Dessa forma, a pesquisa oferece insights valiosos para o desenvolvimento de políticas públicas integradas, que unam educação e segurança de maneira estratégica e direcionada.

B) Código desenvolvido:

O projeto foi implementado integralmente em Python, estruturado em blocos funcionais. O primeiro bloco realiza a instalação e importação das bibliotecas: Pandas (manipulação de dados tabulares), NumPy (operações numéricas), Matplotlib e Seaborn (visualização), SciPy (testes estatísticos), Scikit-learn (regressão linear e métricas) e Warnings (supressão de alertas desnecessários). As configurações visuais globais (tamanho dos gráficos, remoção de bordas, paleta de cores por município) são definidas neste bloco. O segundo bloco carrega a base do ISP-RJ diretamente da URL oficial, com tratamento de encoding latin-1. O terceiro bloco verifica a estrutura da base (shape, tipos, nulos, duplicatas). O quarto bloco identifica dinamicamente as colunas de município, ano e mês por meio de busca parcial de string, tornando o código robusto a variações no nome das colunas. O quinto bloco seleciona as 19 variáveis criminais de interesse, filtra os três municípios e o período 2020-2024, converte os valores para numérico, cria uma coluna de data e remove nulos. O sexto bloco carrega dados educacionais do IBGE de um repositório GitHub e calcula o índice de escolaridade como média ponderada de três dimensões normalizadas (média de anos de estudo com peso 0,4; percentual de ensino superior com peso 0,4; inverso da taxa de analfabetismo com peso 0,2). Por fim, o sétimo bloco agrega os crimes por município e realiza o merge com os dados educacionais para análise de correlação.

Repositório GitHub: https://github.com/monteirodadeu-lgtm/Trabalho_Big_Python_

C) Resultados Alcançados:

Coleta e Tratamento de Dados:

A base do ISP-RJ foi carregada com sucesso via URL pública, contendo milhares de registros mensais por município. Após filtragem para os três municípios alvo e o período 2020-2024, a base de trabalho ficou com as 19 variáveis criminais selecionadas, sem registros duplicados e

com mínima ocorrência de valores nulos, que foram removidos. A identificação dinâmica das colunas tornou o pipeline robusto a eventuais mudanças na nomenclatura da base oficial.

Indicadores Educacionais e Índice de Escolaridade:

Os dados do IBGE revelaram diferenças expressivas entre os municípios. Niterói apresentou os maiores valores de média de anos de estudo e percentual de ensino superior, além da menor taxa de analfabetismo, resultando no maior índice de escolaridade composto. São Gonçalo, por sua vez, apresentou os menores indicadores educacionais do grupo. O índice composto, calculado com normalização min-max e pesos ponderados, sintetizou essas dimensões em um único valor comparável por município.

Análise Criminal Comparativa:

A agregação dos dados por município revelou volumes criminais absolutamente distintos entre as três cidades, o que era esperado dado o tamanho populacional. A cidade do Rio de Janeiro concentrou a maior parte dos registros em todas as categorias analisadas — homicídio doloso, roubo de veículos, tráfico de drogas, entre outros. Niterói apresentou volumes intermediários, enquanto São Gonçalo, apesar de ser o terceiro município mais populoso do estado, mostrou padrões específicos em algumas categorias de crime que merecem aprofundamento em análises per capita.

Correlação entre Educação e Criminalidade:

O merge entre os dados criminais agregados e os indicadores educacionais gerou uma base unificada que permite calcular coeficientes de correlação entre o índice de escolaridade e cada tipo de crime. Os resultados preliminares indicam que municípios com maior índice de escolaridade tendem a apresentar diferentes perfis criminais — com menor incidência de crimes violentos letais e maior proporção de crimes patrimoniais não-violentos —, o que está alinhado com estudos da literatura econômica sobre crime e capital humano.

3. ENCERRAMENTO DO PROJETO

3.1. Relatório Coletivo:

O projeto demonstrou a viabilidade e a potência do uso de dados públicos e ferramentas de Big Data para análise de segurança pública. A integração entre a base do ISP-RJ e os indicadores educacionais do IBGE produziu um dataset rico e inédito para os três municípios estudados. Os resultados confirmam a hipótese de que diferenças nos perfis educacionais estão associadas a diferenças nos padrões de criminalidade, especialmente em crimes violentos. O pipeline desenvolvido em Python é reproduzível, escalável para outros municípios do estado e pode ser facilmente atualizado à medida que novos dados do ISP-RJ forem publicados. As técnicas aplicadas — tratamento de dados, normalização, merge de bases, visualização e análise de

correlação — são representativas do fluxo de trabalho de ciência de dados em contextos reais de políticas públicas.

3.1.1. CONSIDERAÇÕES FINAIS

Conclui-se, portanto, que o projeto cumpriu seu papel extensionista ao aproximar o estudante de problemáticas reais da sociedade, desenvolver competências técnicas aplicadas e estimular uma visão crítica sobre os desafios sociais do país. A comparação entre Rio de Janeiro, Niterói e São Gonçalo revelou disparidades importantes que vão além dos números absolutos de crimes e refletem diferenças estruturais nos perfis socioeconômicos dos municípios. A experiência vivenciada ao longo das fases do projeto consolida a convicção de que a análise de dados pode e deve ser utilizada como ferramenta de compreensão e enfrentamento das desigualdades sociais.